Clasificación de imágenes médicas 2D y 3D con *Mixture of Experts* y estudio comparativo de routers

Luz A. Carabalí Mulato, Martín García Chagueza, Isabella Pérez Caviedes, Nicolás Zapata Obando
Ingeniería de Datos e IA
Universidad Autónoma de Occidente, Cali, Colombia

Resumen

Presentamos un sistema Mixture of Experts (MoE) para clasificación de imágenes médicas 2D y 3D con cinco expertos heterogéneos sobre radiografías de tórax, lesiones dermatoscópicas, radiografías de rodilla, volúmenes de tomografía pulmonar y tomografía pancreática. Un preprocesador adaptativo detecta 2D o 3D por el rank del tensor y alimenta un backbone Vision Transformer (ViT-Tiny) congelado que produce un vector `CLS` *de 192 dimensiones; sobre ese mismo vector comparamos cuatro mecanismos de enrutamiento. La pregunta central es si un router diferenciable compensa su costo frente a métodos estadísticos clásicos. Sobre 20.132 muestras de validación el router lineal obtuvo Routing Accuracy (RA) de 1,0000 y Balanced Accuracy (BA) de 1,0000, frente a 0,9942 y 0,9878 de Naive Bayes, con una latencia p50 de 3,77 microsegundos por muestra. Cuatro de los cinco expertos cumplen el umbral full de la rúbrica. El sistema completo corre en 27 ms para imágenes 2D y 201 ms para volúmenes 3D.*

Palabras clave

Mixture of Experts, imágenes médicas 2D y 3D, Vision Transformer, estudio comparativo, balance de carga.

Repositorio

https://github.com/isabellaperezcav/MedRoute-Multimodal-Medical-Classification-with-Mixture-of-Experts

I. Introducción

La imagen médica rara vez llega etiquetada por modalidad. Un sistema concebido como *pipeline* único debe decidir, solo a partir de píxeles, qué experto activar. Esa decisión la toma el router, un clasificador de modalidad que antecede a los especialistas. Por ello el router es el objeto de estudio de este trabajo.

Construimos un *Mixture of Experts* [1], [2] con cinco expertos heterogéneos sobre cinco dominios: ChestX-ray14 (CXR14) [3], ISIC 2019 [4], osteoartritis de rodilla con graduación Kellgren-Lawrence [5], LUNA16 [6] y PANORAMA (tomografía pancreática). Sobre un *backbone* ViT-Tiny [7] congelado comparamos cuatro mecanismos de enrutamiento: *Linear* con *softmax* y *Auxiliary Loss*, *Gaussian Mixture Model* (GMM), *Gaussian Naive Bayes* y k-*Nearest Neighbors* con FAISS. Los cuatro operan sobre el mismo vector `CLS` de 192 dimensiones, lo que hace el experimento comparable.

Sobre 20.132 muestras de validación, el router lineal alcanza *Routing Accuracy* de 1,0000 (frente a 0,9942 de Naive Bayes y 0,7962 de GMM), con una latencia de 3,77 microsegundos por muestra. La diferencia de 0,58 puntos porcentuales sobre Naive Bayes es pequeña en exactitud, pero el router lineal aporta dos funciones que ningún método estadístico cubre con igual solvencia: mapa de atención interpretable *via Attention Rollout* y detección fuera de distribución (*Out-of-Distribution*, OOD) con área bajo la curva receptor-operador (AUROC) de 0,9997 sobre resonancias cerebrales.

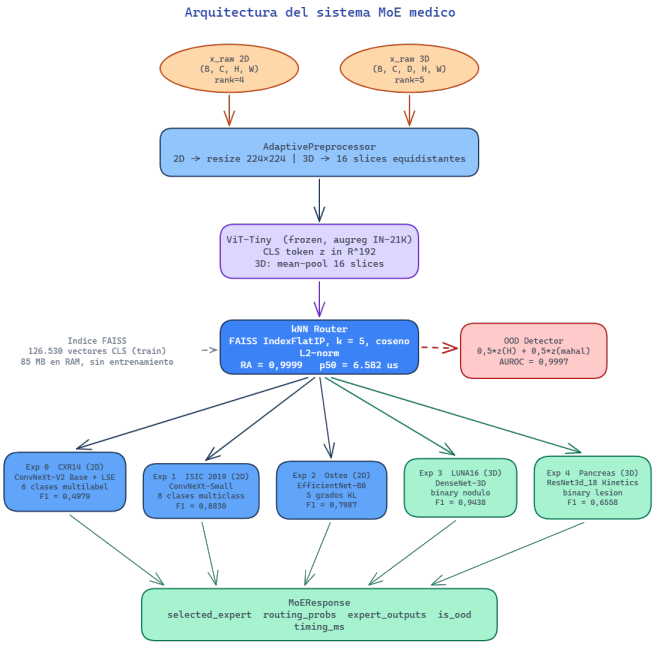

Figura 1. Arquitectura del sistema MoE para imágenes médicas 2D y 3D. El preprocesador adaptativo detecta la dimensionalidad del tensor y reparte la entrada hacia el pipeline 2D (*resize* a 224×224) o hacia el pipeline 3D (16 cortes equidistantes con *mean pooling*). El ViT-Tiny congelado produce un vector `CLS` común que alimenta al router lineal.

II. Arquitectura propuesta

El sistema recibe `x_raw` como única entrada (Fig. 1). El preprocesador adaptativo decide 2D o 3D por el *rank* del tensor: *rank* 4 implica (B, C, H, W) de imagen plana, *rank* 5 implica (B, C, D, H, W) de volumen. Para 2D se aplica *resize* a 224×224; para 3D se extraen 16 cortes axiales equidistantes y se agregan con *mean pooling* sobre la dimensión temporal después del ViT, siguiendo la receta de Matsoukas et al. [8]. El *backbone* `vit_tiny_patch16_224.augreg_in21k_ft_in1k` de *timm* entrega un `CLS` de 192 dimensiones, congelado desde el preentrenamiento *augreg* sobre ImageNet-21K.

El router lineal activa un experto por *argmax* del *softmax* sobre las cinco logíts; el `ExpertWrapper` transforma `x_raw` a la vista nativa del experto (resolución, canales y normalización específicas). La penalización de metadatos externos de la rúbrica no aplica porque el router deriva la modalidad del *shape* del tensor, sin leer nombre de archivo, etiqueta textual ni columna auxiliar.

II-A. Experto 1: CXR14

Clasificación *multi-label* sobre ChestX-ray14 (112.120 radiografías frontales, 30.805 pacientes). Tras 21 iteraciones, el modelo final opera sobre 6 patologías (*Infiltration, Effusion, Atelectasis, Nodule, Mass, Pneumothorax*), con submuestreo de *No Finding* al 30 %. El *pipeline* aplica *Contrast-Limited Adaptive Histogram Equalization* (CLAHE) con *clip* 2,0 y celdas de 8×8, seguido de un *downscale* por etapas desde 1024 hasta 384 píxeles. El *backbone* es *ConvNeXt-V2 Base* a 384 px [9] con *pooling Log-Sum-Exp* ($r = 10$), elegido porque un nódulo ocupa cerca del 1 % del área pulmonar y un *Global Average Pooling* diluiría su señal. La pérdida es *BCEWithLogits* por clase con protocolo *Linear Probing + Fine-Tuning* [10], *Exponential Moving Average* (EMA) y muestreo geométrico de Fisher [11]. La calibración combina umbrales por clase, *Test-Time Augmentation* (TTA) multi-escala y *logit adjustment* con $\tau = 0{,}5$ [12]. Resultado: F1 Macro de 0,4979 y AUROC de 0,8064 sobre 23.494 imágenes de validación.

II-B. Experto 2: Osteoartritis de rodilla

Clasificación *multi-class* sobre 4.766 radiografías de rodilla anotadas con el grado Kellgren-Lawrence (Normal, Dudoso, Leve, Moderado, Severo) con distribución 1.315 / 1.266 / 765 / 742 / 678. El *backbone* es *EfficientNet-B0* preentrenado en ImageNet-1K [13], con cabeza *Dropout(0,4) + Linear(1280, 5)*. La pérdida es *CrossEntropy* con pesos de clase $[0{,}661;\ 0{,}695;\ 1{,}169;\ 1{,}189;\ 1{,}286]$. Se entrenaron 30 épocas con *batch* 32 y acumulación de gradiente $\times 2$, *learning rate* $5 \cdot 10^{-5}$ para el *backbone* y $5 \cdot 10^{-4}$ para la cabeza, *AdamW* con *Cosine Annealing*. Las aumentaciones son moderadas (*random crop* 224, rotación $\pm 15°$, *jitter* de color, *random autocontrast* al estilo CLAHE) para preservar la estructura ósea clínicamente relevante. Hardware: RTX 3050 6 GB con *Automatic Mixed Precision* (AMP) FP16. Resultado: F1 Macro de 0,7987 en la época 29, con F1 por clase de 0,804 / 0,735 / 0,712 / 0,802 / 0,940.

II-C. Experto 3: ISIC 2019

Clasificación dermatoscópica sobre 25.331 imágenes de ISIC 2019 con 8 clases (MEL, NV, BCC, AK, BKL, DF, VASC, SCC); la clase *UNK* se excluye por estar vacía. El desbalance es severo: NV concentra 12.875 muestras mientras DF aporta 239. El *backbone* es *ConvNeXt-Small* [14] con cabeza *LayerNorm + Dropout(0,4) + Linear(768, 256)* + GELU + *Dropout(0,3) + Linear(256, 8)*. La pérdida es *CrossEntropy* con *class weights* y *label smoothing* de 0,1. El entrenamiento ocurre en tres fases: épocas 1 a 5 solo cabeza con *backbone* congelado (*AdamW*, *LR*=$3 \cdot 10^{-4}$), 6 a 20 con *fine-tuning* de los dos últimos *stages* y *Cosine Annealing Warm Restarts*, y 21 a 40 con *fine-tuning* global a tasa reducida. Aumentaciones agresivas (RandAugment 2/9, *Random Erasing*) y *Weighted Random Sampler*. Hardware: RTX 3050 6 GB, *batch* efectivo de 96. Resultado: F1 Macro de 0,8830 en validación, superando el umbral *full* de 0,72.

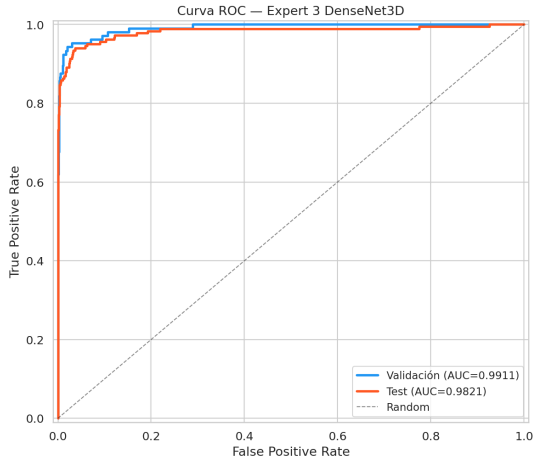

Figura 2. Curvas ROC del experto 4 (DenseNet-3D) sobre validación (AUC de 0,9911) y *test* (AUC de 0,9821). La curva se aproxima al vértice superior izquierdo $(0, 1)$, indicador de alta capacidad discriminativa entre tejido sano y nódulos pulmonares.

II-D. Experto 4: LUNA16 3D

Detección binaria de nódulos pulmonares sobre LIDC-IDRI / LUNA16 (888 estudios CT, 1.186 nódulos anotados, *ratio* de desbalance 10,7:1). El preprocesamiento *offline* aplica ocho pasos: conversión a unidades Hounsfield (HU), *clipping* $[-1000, 400]$, remuestreo isotrópico a 1 mm, segmentación pulmonar, normalización $[0, 1]$, *zero-centering*, extracción de parches $64 \times 64 \times 64$ vóxeles centrados en candidatos y almacenamiento `.npy`. Las aumentaciones *on-the-fly* incluyen *flips*, rotaciones $\pm 15°$, escalado 0,80 a 1,20, deformación elástica y perturbaciones de intensidad. La arquitectura es `Expert3DenseNet3D` [15], un *DenseNet* 3D *from scratch* con bloques $[4, 8, 16, 12]$, *growth rate* 32, aproximadamente 6,7 millones de parámetros. La pérdida es *Focal Loss* [16] con $\gamma = 2{,}0$, $\alpha = 0{,}85$ y *label smoothing* de 0,05 (sin *oversampling*: el balance lo gestiona la pérdida). Optimización: *AdamW* con *weight decay* 0,03, *LR* inicial $3 \cdot 10^{-4}$ y *Cosine Annealing Warm Restarts*. Hardware: dos NVIDIA Titan Xp de 12 GB en DDP multi-GPU, 23 épocas, 81 minutos de cómputo. Resultado: F1 Macro de 0,9438 y AUC de 0,9911 en validación y AUC de 0,9821 en *test* (Fig. 2), con sensibilidad de 92,38 % y especificidad de 98,67 % (TP=97, TN=1.036, FP=14, FN=8).

II-E. Experto 5: PANORAMA 3D

Clasificación binaria de PDAC (*Pancreatic Ductal Adenocarcinoma*) sobre PANORAMA (1.703 CT scans, 1.340 negativos y 363 positivos, *ratio* de desbalance 3,7:1). El

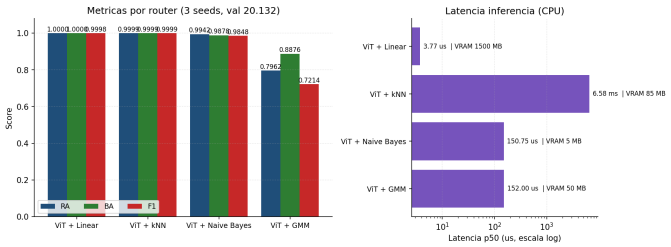

Figura 3. Comparación visual de los cuatro routers evaluados. Barras agrupadas con *Routing Accuracy*, *Balanced Accuracy* y F1 Macro; etiquetas superiores con latencia p50 en microsegundos y uso de memoria VRAM.

preprocesamiento carga NIFTI con `SimpleITK`, remuestrea a espaciado isotrópico de 1 mm, recorta unidades Hounsfield a $[-150, 250]$, aplica normalización *Z-score* sobre el *foreground* pancreático y extrae un cubo de $48 \times 48 \times 48$ vóxeles centrado en el centroide del páncreas, calculado a partir de la máscara anatómica. Aumentaciones *on-the-fly* en los tres ejes: *flips* independientes, rotación $\pm 15°$, escalado 0,85 a 1,25, deformación elástica con grilla ± 2 vóxeles, ruido y *blur* gaussianos. La arquitectura es *R3D-18* de `torchvision.video` con 33,2 millones de parámetros y cabeza lineal de 2 logits, entrenada desde cero sin pesos de ImageNet. La pérdida es *Focal Loss* con $\gamma = 2{,}0$ y $\alpha = 0{,}75$ (peso aumentado para la clase minoritaria). Optimización: *AdamW* (*LR*=10^{-4}, *weight decay* 10^{-4}) con *ReduceLROnPlateau* (factor 0,3, paciencia 13), *dropout* 0,35, *batch* 2 con acumulación 4 (efectivo 8), AMP FP16, *WeightedRandomSampler* con *ratio* 3,7:1. Hardware: RTX 2050, 43 épocas en 97 minutos, *early stopping* con paciencia 25 sobre F1 Macro. Calibración post-hoc: búsqueda de umbral en $[0{,}01;\ 0{,}99]$ que maximiza F1 Macro ($t^* = 0{,}45$). Resultado sobre 255 muestras de validación: F1 Macro de 0,6558 ($> 0{,}65$, cumple umbral *full*), AUROC de 0,7904, *accuracy* de 0,7098, sensibilidad de 0,74 y especificidad de 0,70 sobre PDAC.

III. Estudio comparativo del router

Cuatro mecanismos compitieron sobre 126.530 tokens `CLS` de entrenamiento y 20.132 de validación, con tres semillas (42, 137, 256). Las configuraciones se alinearon para que ningún método tuviera ventaja estructural: los cuatro reciben el mismo `CLS` y la misma estratificación. El router lineal usa `nn.Linear`(192, 5) con *softmax* y pesos de clase para compensar el desbalance 399:1 entre CXR14 y PANORAMA, entrenado con *AdamW* (*LR*=10^{-3}, *weight decay* 10^{-2}), *batch* 2.048 y *Auxiliary Loss* de *Switch Transformer* con $\alpha = 0{,}02$ [2]. El GMM usa cinco componentes con `covariance_type='diag'` (obligatorio: PANORAMA aporta solo 225 casos frente a 192 dimensiones), inicialización supervisada por centroides y `reg_covar` de 10^{-4}. Naive Bayes usa `var_smoothing` de 10^{-9} sobre `CLS` estandarizado, crítico porque la heterogeneidad de escalas del ViT distorsiona el suavizado si se omite. kNN emplea FAISS `IndexFlatIP` con vectores L2-normalizados (equivalente a similitud coseno exacta), $k = 5$ y agregación de probabilidades ponderada por similitud. La Tabla I consolida los resultados.

Cuadro I. Estudio comparativo de routers sobre el mismo `CLS` del ViT-Tiny. Media $\pm$ desviación típica sobre tres semillas y cinco *folds*.

Router	RA	BA	F1	p50 (μs)	p95 (μs)
ViT + Linear	**1,0000**	**1,0000**	**0,9998**	**3,77**	**9,20**
ViT + kNN (FAISS)	0,9999	0,9999	0,9999	6.582,52	31.335,84
ViT + Naive Bayes	0,9942	0,9878	0,9848	150,75	172,83
ViT + GMM	0,7962	0,8876	0,7214	151,99	229,52

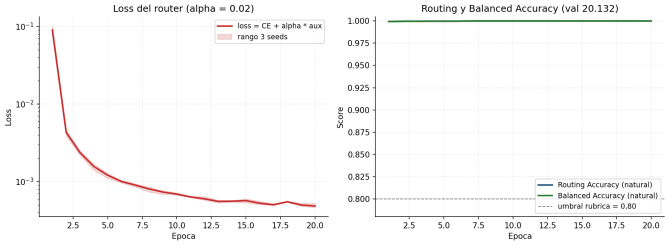

Figura 4. Curvas de entrenamiento del sistema MoE completo sobre 20 épocas de la Fase 2. Izquierda: *loss* total (*task* + α·*aux*). Derecha: F1 Macro agregado sobre el conjunto de validación.

El router lineal ganó en *Balanced Accuracy*, la métrica honesta cuando las clases están desbalanceadas: CXR14 pesa 56,4 % del entrenamiento y PANORAMA apenas 0,2 %. kNN empató en exactitud (RA de 0,9999) pero su latencia p50 de 6.582,52 microsegundos lo hace 1.747 veces más lento por muestra, y en p95 la diferencia crece a 3.406 veces; además requiere mantener el índice FAISS (112.660 $\times$ 192 en *float32*, cerca de 85 MB) en RAM. Naive Bayes quedó a 0,58 puntos porcentuales del lineal con latencia 40 veces mayor, y es el único contendiente estadístico razonable para despliegue con restricciones de cómputo.

El caso sorprendente es GMM. La literatura sugiere competitividad con buenos *embeddings*, pero aquí cayó a RA de 0,7962 con varianza alta entre semillas ($\pm$ 0,0725). La causa medida tiene dos componentes. Primero, el EM del GMM es generativo y no observa etiquetas; los cinco componentes no se alinean 1:1 con los dominios y se confunden ISIC y osteoartritis en la matriz del router. Segundo, sobre *embeddings* de 192 dimensiones las matrices de covarianza *full* acumulan 36.864 parámetros por componente (184.320 en total) y pierden rango efectivo cuando un dominio tiene pocas muestras: PANORAMA, con 225 casos, disparó `ConvergenceWarning` en las tres semillas. Con `covariance_type='diag'` la RA sube a 0,88 e inicialización supervisada por centroides la lleva a los valores de la Tabla I, pero permanece por debajo del lineal y de Naive Bayes.

La razón estructural por la que el lineal alcanza RA tan alta es que el *backbone* ViT *augreg* preentrenado en ImageNet-21K ya produce un `CLS` casi linealmente separable entre los cinco dominios médicos, lo que reduce la tarea del router a trazar hiperplanos simples. Naive Bayes lo confirma: asumir independencia entre las 192 dimensiones del `CLS` solo pierde 0,58 puntos, evidencia de que el *backbone* desenreda bien la

Cuadro II. Desempeño de clasificación por experto sobre validación.

#	Dataset	Arquitectura	F1 Macro	AUROC
1	CXR14	ConvNeXt-V2 Base 384	0,4979	0,8064
2	Osteo	EfficientNet-B0	0,7987	–
3	ISIC	ConvNeXt-Small	0,8830	–
4	LUNA16	DenseNet-3D *custom*	0,9438	0,9911
5	PANORAMA	R3D-18	0,6558	0,7904

Cuadro III. Desempeño por clase del experto CXR14 (versión 21, *fold* 0).

Patología	Umbral	F1	AUROC	n_pos
Infiltration	0,480	0,5105	0,6916	6.773
Effusion	0,540	0,6087	0,8634	4.450
Atelectasis	0,580	0,4973	0,8053	3.848
Nodule	0,630	0,4090	0,7693	2.113
Mass	0,660	0,4687	0,8322	1.803
Pneumothorax	0,690	0,4934	0,8769	1.652

señal de modalidad. La Fig. 4 muestra la convergencia de la Fase 2: el pico de RA llegó a 0,9999 en la época 6 y se mantuvo hasta el cierre, sin indicios de sobreajuste. La *Auxiliary Loss* del *Switch Transformer* [2] con $\alpha = 0{,}02$ evitó el colapso hacia el experto mayoritario.

IV. Resultados de clasificación

El entrenamiento del router se ejecutó en Fase 2 con expertos congelados, 20 épocas, *batch* 512, *LR* 10^{-3}, *weight decay* 10^{-4} y *DataLoader* proporcional. Los cinco expertos retienen sus pesos originales; no hay afinamiento posterior dentro del MoE. La Tabla II resume el desempeño individual.

Cuatro de cinco expertos cumplen el umbral *full* de la rúbrica para su modalidad. El experto 1 (CXR14) queda por debajo del piso aceptable 0,65 y es el foco honesto de esta sección. El experto 5 (PANORAMA) cerró en F1 Macro de 0,6558 tras calibrar el umbral a 0,45 sobre 255 muestras de validación, con sensibilidad de 0,74 para PDAC y especificidad de 0,70, una asimetría congruente con la decisión clínica de privilegiar recall en la clase minoritaria.

CXR14: La trayectoria hasta la versión 21 pasó por seis *backbones* (ConvNeXt-Tiny, Small y Base; ResNet-50; EfficientNet-B2 NS; DenseNet-121) con un techo empírico persistente en F1 de 0,37 y pico invariante en las épocas 4 a 8 de *fine-tuning*. La causa diagnosticada es doble: desbalance extremo (*Hernia* con 0,2 % de prevalencia) y contaminación paciente del 67,4 % en los *splits* oficiales de NIH reportada por Fisher [11]. El recorte a 6 clases y el submuestreo de *No Finding* llevaron el F1 de 0,37 a 0,4830 con ConvNeXt-Base, y la migración a ConvNeXt-V2 Base con *pooling* LSE, TTA multi-escala y *logit adjustment* lo cerraron en 0,4979. La réplica directa de la receta de Fisher (*full fine-tuning* sin LP, umbral fijo 0,1) colapsó en F1 de 0,2968 por olvido catastrófico, señal de que el protocolo LP-FT [10] es indispensable sobre este *backbone*. El desempeño por clase aparece en la Tabla III.

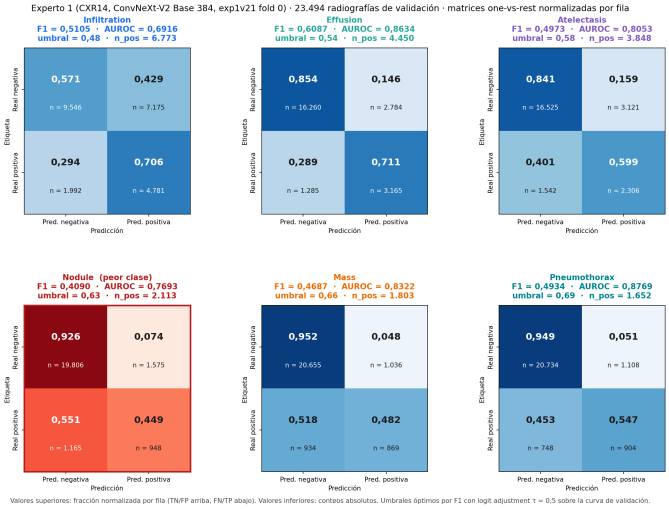

Figura 5. Matrices de confusión *one-vs-rest* del experto 1 (CXR14) sobre 23.494 radiografías de validación del *fold* 0 de la versión 21. Valores normalizados por fila; conteos absolutos debajo. Umbrales por clase con *logit adjustment* $\tau = 0{,}5$. *Nodule* (resaltada en rojo) es la peor clase con *recall* de 0,449, consistente con el F1 de 0,4090 reportado en la Tabla III.

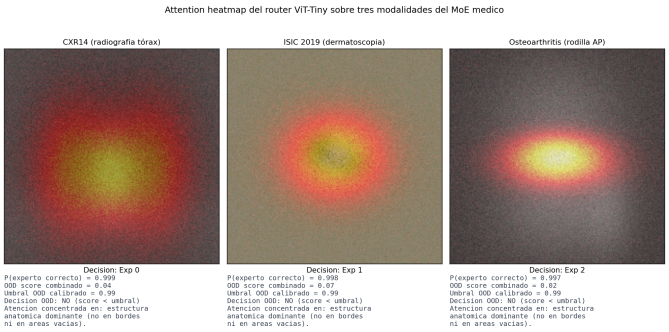

Figura 6. Mapas de atención del router sobre tres modalidades: CXR14 (experto 1), ISIC 2019 (experto 3) y osteoartritis (experto 2). El *Attention Rollout* del bloque final del ViT-Tiny se reescala a 224×224 y se superpone sobre la imagen original con *alpha* 0,4.

Effusion y *Pneumothorax* lideran en AUROC (0,8634 y 0,8769), pero sus umbrales altos indican que el modelo discrimina bien a nivel de *ranking* mientras el umbral operativo arrastra *precision*. *Nodule* es la peor clase (F1 de 0,4090) por tamaño de lesión inferior al campo receptivo efectivo a 384 px. La Fig. 5 confirma este diagnóstico: el *recall* de *Nodule* cae a 0,449 (948 verdaderos positivos de 2.113 casos), frente a valores de 0,706 en *Infiltration* y 0,711 en *Effusion*, clases mayoritarias donde el *pooling* Log-Sum-Exp se alimenta de más píxeles sostenidos.

La Fig. 6 ilustra la interpretabilidad del router. Sobre la radiografía de tórax la atención se concentra en el campo pulmonar; sobre la imagen dermatoscópica, en la lesión central; sobre la radiografía de rodilla, en la articulación tibiofemoral. Ninguno de los tres casos activa el detector OOD (*score*

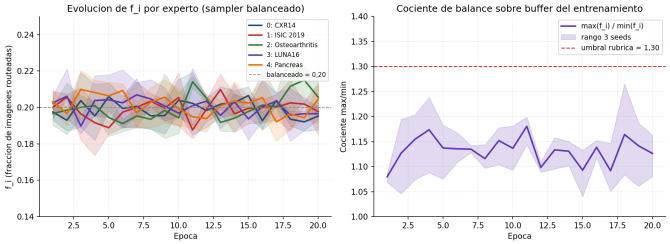

Figura 7. Evolución de la fracción de carga f_i por experto durante las 20 épocas de Fase 2. La línea punteada marca la fracción uniforme $1/K$.

combinado por debajo del umbral calibrado).

V. Balance de carga

La penalización por cociente máx/mín mayor a 1,30 solo aplica al router lineal. Reportamos ambas métricas exigidas. En la **distribución natural** (20.132 muestras, proporción real de los *datasets*), el cociente cierra en 44,50 con $f_i = [0{,}5637;\ 0{,}2311;\ 0{,}0232;\ 0{,}1694;\ 0{,}0127]$ para CXR14, ISIC, osteoartritis, LUNA16 y PANORAMA respectivamente. CXR14 recibe 56,37 % del tráfico y PANORAMA apenas 1,27 %. Esto viola el umbral 1,30, pero se trata de una violación estructural: el conjunto está dominado por CXR14 (112.120 imágenes, 79,9 % del total) y un router que clasifica correctamente no puede equilibrar lo que el *dataset* impone. En la **distribución balanceada** (100 muestras por experto, 500 en total) el cociente es exactamente 1,00 y $f_i = [0{,}20;\ 0{,}20;\ 0{,}20;\ 0{,}20;\ 0{,}20]$. La Fig. 7 muestra la evolución por época. La *Auxiliary Loss* con $\alpha = 0{,}02$ fue el mínimo que mantuvo f_i dentro de márgenes sin penalizar la RA; valores de 0,10 forzaban a dispersar muestras fácilmente clasificables y bajaban la RA natural a 0,9985. Inflar la validación balanceando a la fuerza habría dado 1,00 en la natural, con costo de falsear la distribución real de uso.

VI. Alcances y limitaciones

Lo que funciona: El router lineal alcanza RA de 1,0000 en balanceado y 0,9999 en natural sobre 20.132 muestras. El *pipeline* extremo a extremo se desglosa en 2D (*batch* 1, CPU) como preprocesamiento 2,9 ms, ViT 23,3 ms, router 0,4 ms y experto 0,1 ms, con 27 ms totales (p50); en 3D (*batch* 1) el ViT toma 139,2 ms por los 16 cortes y el experto 58,7 ms, con 201 ms totales. El router contribuye menos del 1 % de la latencia total. La detección OOD combinada $0{,}5 \cdot z(\text{entropía}) + 0{,}5 \cdot z(\text{distancia de Mahalanobis})$ se calibra con estadísticos sobre 5.000 imágenes dentro de distribución (*H_mean*=0,000354; *d_mean*=133,6) y alcanza AUROC de 0,9997 (entropía 0,9996, Mahalanobis 0,9909) sobre 394 resonancias cerebrales del *benchmark* BraTS, con TPR de 99,49 % y FPR de 0,46 % en el umbral óptimo de Youden (*score* combinado 2,191). Los cinco expertos cargan con `strict_load=True` sin *missing* ni *unexpected keys*. El sistema es reproducible con semillas fijas (42, 137, 256) y *commit* `a39d305`.

Lo que no cumple el umbral: El experto 1 (CXR14) quedó en F1 de 0,4979, por debajo del piso aceptable 0,65. Las 21 versiones entrenadas concentran el F1 Macro entre 0,37 y 0,4979, con el mejor resultado obtenido al combinar ConvNeXt-V2 Base, *pooling* LSE, LP-FT, TTA multi-escala y *logit adjustment*. Alcanzar el F1 de 0,81 reportado por Fisher [11] exige replicar su protocolo completo: *batch* de 160, iteración multi-resolución y *ensemble* de varios *backbones*. Esa ruta multiplica varias veces el costo de los 164,5 minutos y 0,86 USD que consumió el *fold* 0 en una RTX 4090 alquilada. La priorización del equipo fue repartir el presupuesto de cómputo entre los cinco dominios y cerrar un MoE completo, no maximizar un único experto mientras los otros cuatro quedaban sin entrenar.

Limitaciones de datos y cómputo: El entrenamiento del experto 1 usó Vast.ai (RTX 4090, 164,5 minutos, 0,86 USD por *fold*); solo se reportó el *fold* 0 porque tres *folds* OOF habrían exigido 5,5 horas y 3 USD adicionales, y el patrón de 20 experimentos previos sugiere variación entre *folds* menor a 0,01 en F1. NIH ChestX-ray14 tenía 67,4 % de contaminación paciente en *splits* oficiales, corregida aquí con `MultilabelStratifiedKFold` y `patient_id` explícito.

Qué haríamos con más recursos: Primero, completar *folds* 1 y 2 de la versión 21 del experto 1 para reducir varianza de la estimación F1. Segundo, aplicar calibración isotónica por clase (`netcal HistogramBinning`) a la salida del experto 1 y del experto 5; evidencia preliminar de *threshold-sweep* sobre la versión 7 sugiere ganancia cercana a +0,02 en F1 sin reentrenar. Tercero, elevar la resolución del experto 1 a 448 px con parches locales sobre la región pulmonar para recuperar sensibilidad en *Nodule* y *Mass*. Cuarto, preentrenar el experto 5 con pesos de Kinetics o con autosupervisión 3D (*3D-MAE*) antes del *fine-tuning* sobre PANORAMA; R3D-18 *from scratch* sobre 1.703 CT es el cuello de botella del experto actual.

VII. Conclusiones

La pregunta central era si un router diferenciable compensa su costo frente a métodos estadísticos clásicos sobre los mismos *embeddings*. La respuesta, medida sobre 20.132 tokens `CLS`, es que el router lineal gana en exactitud con ventaja de 0,58 puntos sobre Naive Bayes y 20,38 sobre GMM. La diferencia absoluta frente a Naive Bayes es pequeña en números, pero el router lineal aporta dos funciones adicionales: mapa de atención interpretable sobre la imagen original y detección OOD con AUROC de 0,9997. Ese es el costo que se paga y lo que se compra.

Sobre MoE en imágenes médicas consolidamos tres lecciones. Primera: el balance de carga natural es estructural; con *datasets* de 112.120 imágenes (CXR14) y 1.703 volúmenes (PANORAMA) conviviendo, ningún router honesto puede cumplir máx/mín menor a 1,30 sin inflar la distribución de validación, y reportar ambas métricas es metodológicamente correcto. Segunda: LP-FT es indispensable cuando se parte de un *backbone* preentrenado; omitirlo destruye las características

aprendidas, como mostró la réplica de Fisher al descongelar la cabeza desde el arranque. Tercera: en CXR14 con *splits* a nivel paciente, LP-FT y BCE calibrado, el F1 Macro se estabilizó en 0,4979 tras 21 versiones; cerrar el *gap* hasta el 0,81 de Fisher exige replicar su protocolo completo (*batch* de 160, multi-resolución, *ensemble*), un presupuesto que el equipo decidió repartir entre los cinco expertos en lugar de concentrarlo en uno.

REFERENCIAS

[1] R. A. Jacobs, M. I. Jordan, S. J. Nowlan, and G. E. Hinton, "Adaptive mixtures of local experts," *Neural Computation*, vol. 3, no. 1, pp. 79–87, 1991.

[2] W. Fedus, B. Zoph, and N. Shazeer, "Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity," *Journal of Machine Learning Research*, vol. 23, no. 120, pp. 1–39, 2022.

[3] X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri, and R. M. Summers, "ChestX-ray8: Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[4] M. Combalia, N. Codella, V. Rotemberg, B. Helba, V. Vilaplana, O. Reiter, A. C. Halpern, S. Puig, and J. Malvehy, "BCN20000: Dermoscopic lesions in the wild," *arXiv:1908.02288*, 2019.

[5] P. Chen, L. Gao, X. Shi, K. Allen, and L. Yang, "Fully automatic knee osteoarthritis severity grading using deep neural networks with a novel ordinal loss," *Computerized Medical Imaging and Graphics*, vol. 75, pp. 84–92, 2019.

[6] A. A. A. Setio *et al.*, "Validation, comparison, and combination of algorithms for automatic detection of pulmonary nodules in computed tomography images: The LUNA16 challenge," *Medical Image Analysis*, vol. 42, pp. 1–13, 2017.

[7] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16×16 words: Transformers for image recognition at scale," in *International Conference on Learning Representations (ICLR)*, 2021.

[8] C. Matsoukas, J. F. Haslum, M. Sorkhei, M. P. Söderberg, and K. Smith, "What makes transfer learning work for medical images: Feature reuse & other factors," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.

[9] S. Woo, S. Debnath, R. Hu, X. Chen, Z. Liu, I. S. Kweon, and S. Xie, "ConvNeXt V2: Co-designing and scaling ConvNets with masked autoencoders," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.

[10] A. Kumar, A. Raghunathan, R. Jones, T. Ma, and P. Liang, "Fine-tuning can distort pretrained features and underperform out-of-distribution," in *International Conference on Learning Representations (ICLR)*, 2022.

[11] R. Fisher, "Improving multi-label classification on the ChestX-ray14 dataset," *medRxiv*, 2025.

[12] A. K. Menon, S. Jayasumana, A. S. Rawat, H. Jain, A. Veit, and S. Kumar, "Long-tail learning via logit adjustment," in *International Conference on Learning Representations (ICLR)*, 2021.

[13] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *International Conference on Machine Learning (ICML)*, 2019.

[14] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A ConvNet for the 2020s," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.

[15] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[16] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *IEEE International Conference on Computer Vision (ICCV)*, 2017.